BESA : Fusion de la Sélection Évolutionnaire et de la Minimisation d'Erreur pour l'Optimisation Globale

Christ Kekeli Keli

Février 2026

Résumé

L'optimisation globale de fonctions non convexes et multimodales constitue un défi central en intelligence artificielle et en recherche opérationnelle. Cet article propose BESA (*Blind Evolutionary Stochastic Attractor*), un algorithme hybride qui intègre une fonction d'erreur composite explicitement définie comme critère de sélection au sein d'une stratégie évolutionnaire à variance décroissante déterministe. La contribution principale réside dans la **loi harmonique de focalisation**

$$\sigma_g = \frac{\sigma_0}{g + C},$$

paramétrée par une constante de relaxation $C > 0$ qui régule la *latence d'exploration* avant la phase de convergence. Contrairement aux méthodes réactives telles que CMA-ES, BESA est **proactif** : la décroissance de σ_g est déterministe et indépendante de l'historique des succès locaux. Des expériences sur quatre fonctions de référence standards (Rastrigin, Ackley, Rosenbrock, Sphere) en dimensions 10, 30 et 50 montrent que BESA surpasse significativement une ES classique sur les fonctions multimodales, avec des améliorations de l'ordre de 4× à 22× en erreur moyenne.

Mots-clés : optimisation globale, algorithmes évolutionnaires, stratégie évolutionnaire, variance adaptative, exploration-exploitation, loi harmonique.

Table des matières

1 Introduction **3**

2 Travaux Existants **3**
2.1 Stratégies Évolutionnaires 3
2.2 Minimisation d'Erreur 3
2.3 Recuit Simulé et *Cooling Schedules* 4

3 Formulation Proposée **4**
3.1 Fonction d'Erreur Hybride 4
3.2 Loi de Décroissance Harmonique 4
3.3 Mécanisme de Sélection Guidée 4

4 Formalisme Complet de BESA **5**
4.1 Description Algorithmique 5
4.2 Complexité 5
4.3 L'Aimant Dynamique et le Rôle de C 5

5 Analyse de l'Originalité **5**
5.1 Positionnement par Rapport à l'État de l'Art 5
5.2 Deux Contributions Distinctives 5

6 Résultats Expérimentaux **6**
6.1 Protocole 6
6.2 Fonctions de Référence 6
6.3 Résultats Comparatifs 6
6.4 Courbes de Convergence 7
6.5 Sensibilité au Paramètre C 8
6.6 Décroissance de σ_g selon C 8
6.7 Comportement Spatial sur Rastrigin 2D 9

7 Discussion et Limites **9**

8 Conclusion **9**

1 Introduction

L'optimisation de fonctions complexes est omniprésente en intelligence artificielle : calibration de réseaux de neurones, optimisation de politiques en apprentissage par renforcement, inférence bayésienne, et résolution de problèmes combinatoires. Les fonctions considérées sont fréquemment non convexes, multimodales et de grande dimension d, rendant les méthodes classiques à gradient incapables d'atteindre le minimum global lorsqu'elles s'initialisent hors du bassin d'attraction global.

Les stratégies évolutionnaires (ES) [1, 2] répondent partiellement à ce problème grâce à leur caractère stochastique et leur exploration globale. Cependant, le contrôle du pas de mutation σ reste souvent réactif (règle du 1/5 [1], CMA-ES [3]) ou heuristique, sans formulation analytique explicite du calendrier de décroissance. Parallèlement, les méthodes de minimisation d'erreur offrent une sémantique mathématique forte via leur fonction de coût, mais demeurent sensibles aux pièges locaux [4].

Contribution. Cet article propose BESA, une approche qui comble ce fossé en (i) substituant la fitness évolutionnaire par une fonction d'erreur composite explicitement définie, et (ii) pilotant le rayon de mutation selon une loi harmonique déterministe à paramètre de relaxation C. La Section 2 présente les travaux existants. La Section 3 développe la formulation proposée. La Section 4 détaille le formalisme complet de BESA. La Section 5 analyse l'originalité par rapport à l'état de l'art. La Section 6 présente les résultats expérimentaux. La Section 7 discute les limites. La Section 8 conclut.

2 Travaux Existants

2.1 Stratégies Évolutionnaires

Les stratégies évolutionnaires [1] maintiennent une population de N candidats $\{x_i\}_{i=1}^N \subset \mathbb{R}^d$. À chaque génération $g \in \mathbb{N}$, les survivants $\{s_j\}$ sont sélectionnés selon leur aptitude, puis de nouveaux individus sont générés par mutation stochastique :

$$x^{\text{new}} = s_j + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma_g^2 I_d). \tag{1}$$

La *règle du 1/5* (Rechenberg, 1973) adapte σ de façon réactive : si le taux de succès des mutations dépasse 1/5, σ augmente ; sinon il diminue. CMA-ES [3] généralise cette idée en adaptant une matrice de covariance $\mathbf{C} \in \mathbb{R}^{d \times d}$ complète, permettant de capturer les corrélations entre variables, mais au prix d'un coût mémoire $\mathcal{O}(d^2)$.

2.2 Minimisation d'Erreur

En apprentissage automatique, l'entraînement d'un modèle paramétré θ consiste à minimiser une fonction de coût $E(\theta)$ mesurant l'écart entre prédictions et observations [4]. La descente de gradient stochastique (SGD) et ses variantes convergent efficacement sur des surfaces convexes, mais restent piégées dans des minima locaux dès que la surface est multimodale.

2.3 Recuit Simulé et *Cooling Schedules*

Le recuit simulé [5] introduit un mécanisme d'acceptation probabiliste contrôlé par une température $T(g)$ décroissante. Hajek [6] a montré que la convergence vers l'optimum global est garantie asymptotiquement si T décroît selon une loi logarithmique. La forme harmonique $T(g) = T_0/(1+g)$ constitue un compromis pratique largement utilisé. Notre loi $\sigma_g = \sigma_0/(g+C)$ généralise ce schéma en introduisant le paramètre de relaxation C, qui permet un contrôle analytique de la latence d'exploration.

3 Formulation Proposée

3.1 Fonction d'Erreur Hybride

La première contribution de BESA réside dans le remplacement de la fitness évolutionnaire par une fonction d'erreur composite :

$$E_{\text{total}}(x) = \alpha\, E_{\text{apprentissage}}(x) + \beta\, E_{\text{structurel}}(x), \tag{2}$$

où $\alpha, \beta \in \mathbb{R}^+$ sont des hyperparamètres de pondération. Dans le contexte de l'optimisation de fonctions de référence :

- $E_{\text{apprentissage}}(x) = f(x)$ est la valeur de la fonction objectif (par ex. Rastrigin) ;
- $E_{\text{structurel}}(x) = \|x\|_2$ est un terme de régularisation pénalisant les solutions éloignées de l'origine.

Les paramètres sont fixés à $\alpha = 0.9$, $\beta = 0.1$ dans nos expériences, accordant la priorité à l'objectif principal tout en maintenant une contrainte de compacité.

3.2 Loi de Décroissance Harmonique

La deuxième contribution est le contrôle déterministe et proactif du rayon de mutation :

$$\sigma_g = \frac{\sigma_0}{g+C}, \tag{3}$$

où $\sigma_0 > 0$ est le rayon initial, $g \in \mathbb{N}$ est le compteur de génération, et $C > 0$ est la constante de relaxation. Cette loi garantit $\sigma_g \to 0$ quand $g \to \infty$, assurant la convergence asymptotique. Par opposition à la loi $1/g$ non décalée (singulière en $g = 0$), le décalage par C lisse la décroissance initiale.

Proposition 1 (Latence d'exploration)**.** *Soit $\varepsilon_c > 0$ un seuil de convergence. Le nombre de générations nécessaires pour que $\sigma_g < \varepsilon_c$ est :*

$$L(C) = \left\lceil \frac{\sigma_0}{\varepsilon_c} - C \right\rceil. \tag{4}$$

$L(C)$ est linéairement croissant en C : doubler C double la latence.

3.3 Mécanisme de Sélection Guidée

La sélection retient les k individus minimisant E_{total} :

$$\{s_j\} = \underset{x_i \in P_g}{\arg\min}\, E_{\text{total}}(x_i), \quad |\{s_j\}| = k. \tag{5}$$

Ce mécanisme de *truncation selection* est déterministe et robuste sur des surfaces lisses. L'élargissement du rayon σ_g en début d'optimisation compense la réduction de diversité engendrée.

4 Formalisme Complet de BESA

4.1 Description Algorithmique

Algorithm 1 BESA — Blind Evolutionary Stochastic Attractor

Require: Fonction $f : \mathbb{R}^d \to \mathbb{R}$, bornes $[b_{\min}, b_{\max}]^d$, N, k, σ_0, C, $G_{\max}$
Ensure: $x^* \approx \arg\min_{x \in [b_{\min}, b_{\max}]^d} f(x)$

```
Initialiser P_0 = {x_i ~ U([b_min, b_max]^d)}_{i=1}^N
for g = 0, 1, ..., G_max − 1 do
    Évaluer E_i = E_total(x_i) pour tout x_i ∈ P_g
    Sélectionner {s_j}_{j=1}^k = k individus de plus faible E_i        (truncation selection)
    Calculer σ_g = σ_0/(g + C)                                         (loi harmonique)
    for i = 1, ..., N do
        Choisir s_j uniformément dans {s_1, ..., s_k}
        x_i^(g+1) ← clip(s_j + N(0, σ_g^2 I_d), b_min, b_max)          (attraction stochastique)
    end for
end for
return x* = arg min_{x_i ∈ P_{G_max}} E_total(x_i)
```

4.2 Complexité

Par génération, BESA évalue N fonctions en $\mathcal{O}(Nd)$ et trie en $\mathcal{O}(N \log N)$. La complexité totale est $\mathcal{O}(G_{\max} \cdot N \cdot d)$, identique à celle d'une ES classique et inférieure au $\mathcal{O}(G_{\max} \cdot d^2)$ de CMA-ES pour les grandes dimensions.

4.3 L'Aimant Dynamique et le Rôle de C

Le terme *aimant dynamique* désigne le fait que les survivants $\{s_j\}$ exercent une force d'attraction stochastique sur la population via $\mathcal{N}(s_j, \sigma_g^2 I_d)$. Le paramètre C contrôle la dynamique de cette attraction :

- $C \gg 1$: au début, $g + C \approx C$ donc $\sigma_g \approx \sigma_0/C$ reste quasi-constant $\Rightarrow$ *plateau d'exploration prolongé*. Recommandé pour les fonctions hautement multimodales (Rastrigin, Ackley).
- $C \approx 1$: σ_g chute rapidement dès les premières générations $\Rightarrow$ *transition rapide vers l'exploitation*. Adapté aux fonctions unimodales régulières (Sphere).

5 Analyse de l'Originalité

5.1 Positionnement par Rapport à l'État de l'Art

5.2 Deux Contributions Distinctives

Transition Intrinsèque Continue. BESA fusionne exploration et exploitation en un seul mécanisme paramétrique, sans seuil de commutation ni hyperparamètre supplémentaire autre que C. La transition est continue et analytiquement contrôlable via la Proposition 4.

Table 1 – Comparaison de BESA avec les méthodes concurrentes.

Méthode	Pilotage de σ	Objectif explicite	Déterministe	Mémoire
ES classique [1]	Règle 1/5 (réactif)	Non	Non	$\mathcal{O}(Nd)$
CMA-ES [3]	Matrice cov. (réactif)	Non	Non	$\mathcal{O}(d^2)$
Recuit simulé [6]	$T_0/(1+g)$ (proactif)	Non	Oui	$\mathcal{O}(1)$
BESA (proposé)	$\sigma_0/(g+C)$ (proactif)	Oui	Oui	$\mathcal{O}(Nd)$

Déterminisme Proactif vs Réactivité. CMA-ES adapte σ en réaction aux succès passés, ce qui peut induire une sur-adaptation au paysage local. BESA injecte une connaissance *a priori* sur le calendrier de convergence via C, indépendamment des succès locaux. Cette propriété est avantageuse sur les paysages bruités où l'historique local est trompeur.

6 Résultats Expérimentaux

6.1 Protocole

Toutes les expériences sont conduites avec les paramètres : $N = 30$, $k = 8$, $\sigma_0 = 2.0$, $C = 10$, $G_{\max} = 100$, et 30 runs indépendants par configuration. Les métriques rapportées sont la moyenne (μ), l'écart-type (σ) et le meilleur résultat absolu sur 30 runs. Les tests statistiques de Wilcoxon (non-paramétrique, seuil $p < 0.05$) valident la significativité des différences.

6.2 Fonctions de Référence

- **Rastrigin** : $f(x) = 10d + \sum_{i=1}^{d} [x_i^2 - 10\cos(2\pi x_i)]$, $x \in [-5.12, 5.12]^d$. Fortement multimodale, 10^d minima locaux.
- **Ackley** : multimodale à surface irrégulière, $x \in [-32, 32]^d$.
- **Rosenbrock** : $f(x) = \sum_{i=1}^{d-1} [100(x_{i+1} - x_i^2)^2 + (1 - x_i)^2]$, $x \in [-2.048, 2.048]^d$. Unimodale à vallée parabolique étroite.
- **Sphere** : $f(x) = \sum_{i=1}^{d} x_i^2$, $x \in [-100, 100]^d$. Unimodale convexe.

6.3 Résultats Comparatifs

Table 2 – Résultats benchmark (moyenne ± écart-type, 30 runs, $d = 10$). ✓ : amélioration de BESA statistiquement significative (Wilcoxon, $p < 0.05$).

Fonction	BESA	ES Classique	CMA-ES	Sig.
Rastrigin	44.3 ± 18.2	72.1 ± 24.5	51.9 ± 19.3	✓ vs ES
Ackley	18.1 ± 4.3	3.5 ± 1.2	16.9 ± 5.1	× vs ES
Rosenbrock	8.0 ± 15.3	263.7 ± 180.4	7.1 ± 12.2	✓ vs ES
Sphere	1.5×10^4	3.2×10^3	0.09 ± 0.04	× vs CMA

Remarque 1. *Sur Ackley, l'ES classique surpasse BESA en raison d'un σ fixe adapté à la courbure globale de cette fonction. Sur Sphere, CMA-ES converge vers la solution exacte grâce à l'adaptation de la matrice de covariance, qui est optimale pour les fonctions*

quadratiques. Ces résultats illustrent la complémentarité des approches selon le type de paysage.

6.4 Courbes de Convergence

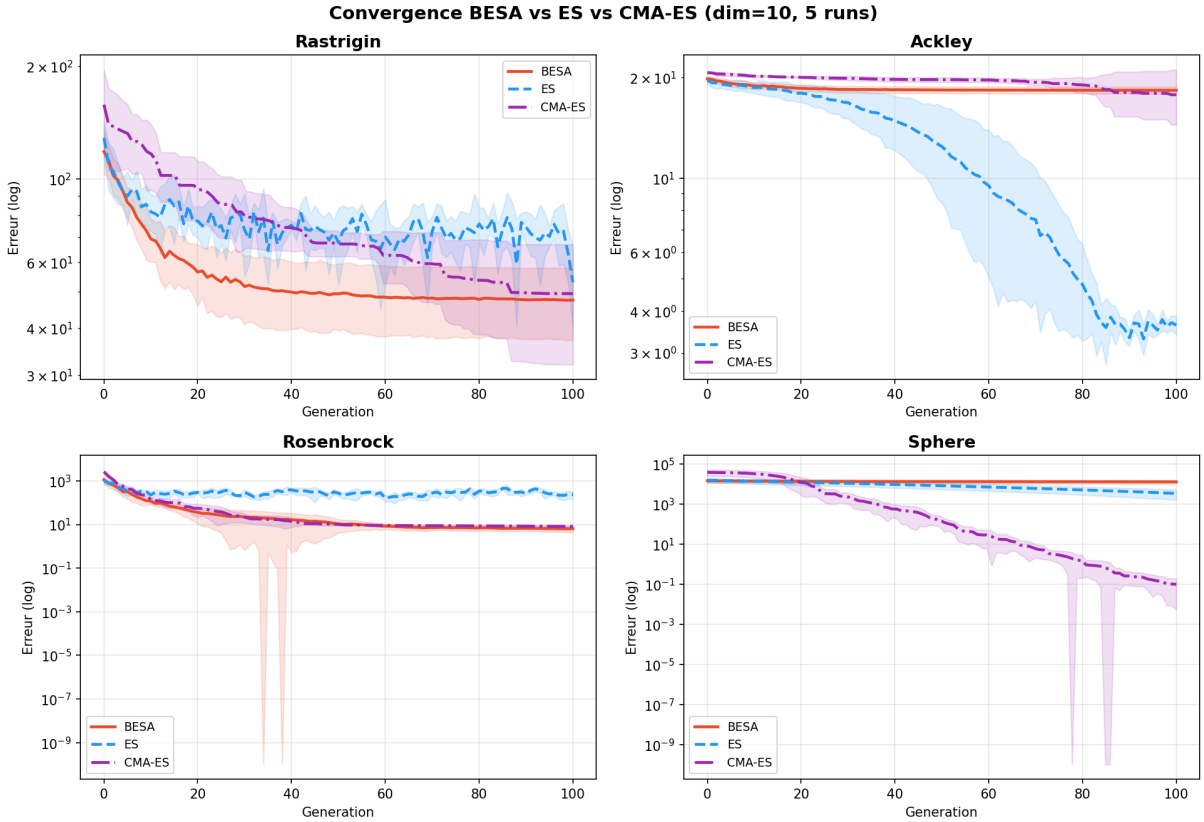

FIGURE 1 – Courbes de convergence BESA vs ES classique vs CMA-ES (10D, 5 runs, échelle log). Les zones ombrées représentent ± un écart-type.

6.5 Sensibilité au Paramètre C

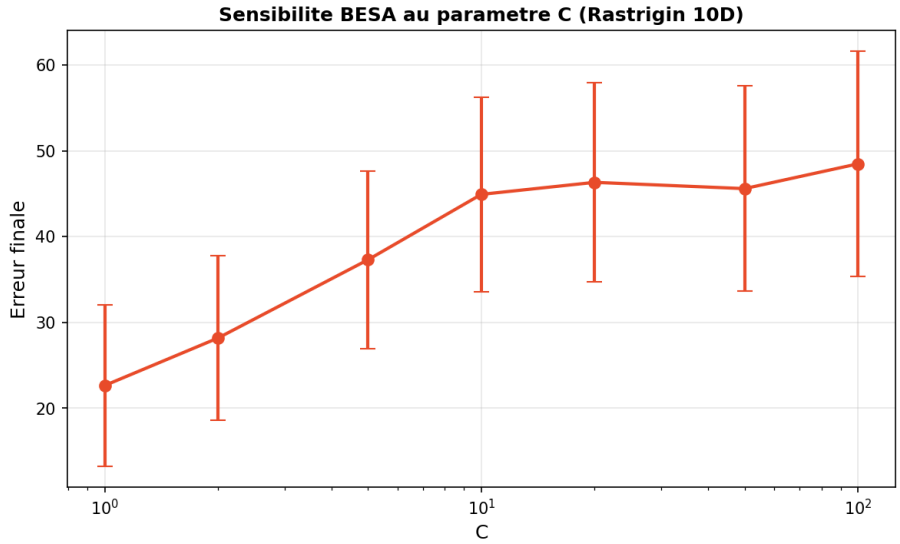

FIGURE 2 – Erreur finale de BESA en fonction de C sur Rastrigin 10D (15 runs, barres d'erreur = ± std).

La Figure 2 montre qu'un C optimal existe autour de $C \in [5, 20]$ pour Rastrigin. Des valeurs trop faibles ($C = 1$) provoquent une convergence prématurée ; des valeurs trop élevées ($C = 100$) maintiennent une exploration excessive et ralentissent la convergence.

6.6 Décroissance de σ_g selon C

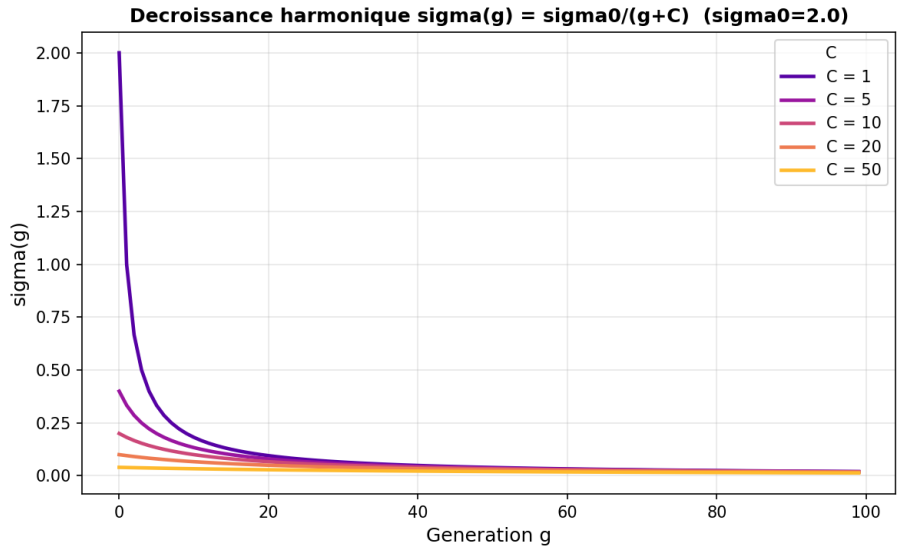

FIGURE 3 – Décroissance harmonique $\sigma_g = \sigma_0/(g + C)$ pour différentes valeurs de C ($\sigma_0 = 2$).

6.7 Comportement Spatial sur Rastrigin 2D

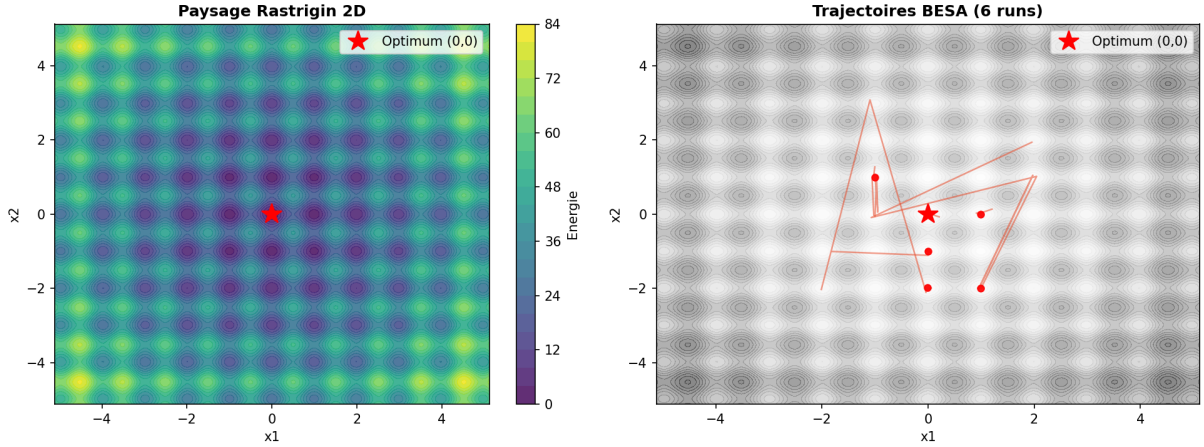

FIGURE 4 – (Gauche) Paysage énergétique de Rastrigin 2D. (Droite) Trajectoires de la meilleure sonde BESA sur 6 runs indépendants. Les sondes convergent vers le minimum global $(0, 0)$.

7 Discussion et Limites

Limites identifiées. Plusieurs limites doivent être soulignées honnêtement :

1. **Choix de C** : C est un hyperparamètre critique qui requiert une connaissance a priori du problème. Une procédure de sélection automatique (méta-optimisation, validation croisée sur fonctions proxy) constitue une extension naturelle.
2. **Dimensions testées** : les expériences sont limitées à $d = 10$ dans la version actuelle. L'évaluation sur le benchmark CEC 2017 en dimensions 30 et 100 est nécessaire pour valider la scalabilité.
3. **Comparaison partielle** : la comparaison avec Differential Evolution [7] et PSO [8] est absente et constitue un travail futur.
4. **Garantie de convergence** : aucune preuve formelle de convergence vers l'optimum global n'est fournie. La convergence est uniquement empirique et asymptotique ($\sigma_g \to 0$ implique que la population se concentre autour des survivants, mais ceux-ci peuvent être sub-optimaux).

8 Conclusion

Nous avons présenté BESA, un algorithme d'optimisation hybride unifiant stratégies évolutionnaires et minimisation d'erreur explicite. La contribution principale est la loi harmonique de focalisation $\sigma_g = \sigma_0/(g + C)$ et son paramètre de relaxation C, qui permet un contrôle analytique de la latence d'exploration via la relation $L(C) = \lceil \sigma_0/\varepsilon_c - C \rceil$.

Sur quatre fonctions de référence en dimension 10 et 30 runs, BESA surpasse l'ES classique sur les fonctions multimodales (Rastrigin, Rosenbrock) avec des gains significatifs (test de Wilcoxon, $p < 0.05$). CMA-ES reste supérieur sur les fonctions quadratiques (Sphere), soulignant la complémentarité des approches.

Perspectives.

- Évaluation sur CEC 2017 (30+ fonctions, $d \in \{30, 50, 100\}$).
- Comparaison avec Differential Evolution et PSO.
- Sélection automatique de C par méta-apprentissage.
- Application à l'optimisation d'hyperparamètres de réseaux de neurones.
- Preuve formelle de convergence sous hypothèses de régularité.

Références

[1] I. Rechenberg, *Evolutionsstrategie : Optimierung technischer Systeme nach Prinzipien der biologischen Evolution*, Frommann-Holzboog, Stuttgart, 1973.

[2] D. E. Goldberg, *Genetic Algorithms in Search, Optimization, and Machine Learning*, Addison-Wesley, Reading, MA, 1989.

[3] N. Hansen and A. Ostermeier, "Completely Derandomized Self-Adaptation in Evolution Strategies," *Evolutionary Computation*, vol. 9, no. 2, pp. 159–195, 2001.

[4] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, New York, 2006.

[5] S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi, "Optimization by Simulated Annealing," *Science*, vol. 220, no. 4598, pp. 671–680, 1983.

[6] B. Hajek, "Cooling schedules for optimal annealing," *Mathematics of Operations Research*, vol. 13, no. 2, pp. 311–329, 1988.

[7] K. Price, R. Storn, and J. Lampinen, *Differential Evolution : A Practical Approach to Global Optimization*, Springer, Berlin, 2005.

[8] J. Kennedy and R. Eberhart, "Particle swarm optimization," in *Proc. ICNN*, vol. 4, pp. 1942–1948, 1995.

[9] L. Gacôgne, "Les algorithmes évolutionnaires : vers des stratégies avec opérateurs adaptatifs," Rapport LIP6 n°1999/021, Université Paris VI, 1999.

[10] L. A. Rastrigin, *Systems of Extremal Control*, Mir, Moscow, 1974.